

Universidade do Minho

Escola de Engenharia

Licenciatura em Engenharia Informática

Mestrado Integrado em Engenharia Informática

Aprendizagem e Decisão Inteligentes

Ano Letivo de 2025/2026

Grupo 14

Pedro Nuno Rebelo Figueiredo

a104354

Diogo Luis Barros Costa

a100751

Tiago Miguel Barroso de Brito

a106796

Nuno Miguel Taveira Melo

a104446

ADI

Índice

1. Introdução	1
2. Dataset Grupo	2
2.1. Domínios e Objetivos	3
2.2. Análise de dados	3
2.2.1. Trip_Distance	3
2.2.2. Time_of_Day	3
2.2.3. Day_of_Week	4
2.2.4. Passengers_Counter	5
2.2.5. Condições de transito	5
2.2.6. Weather	6
2.2.7. Base_Fare	6
2.2.8. Per_Km_Rate	7
2.2.9. Per_Minute_Rate	7
2.2.10. Trip_Duration_Minutes	7
2.2.11. Trip_Price	8
2.3. Tratamento de dados	8
2.3.1. Correlação entre as diferentes tabelas	8
2.3.2. Tratamento dos <i>missing values</i>	9
2.3.2.1. Processo A	9
2.3.2.1.1. Ideia	9
2.3.2.1.2. Tratamento	9
2.3.2.2. Processo B	10
2.3.2.2.1. Ideia	10
2.3.2.2.2. Tratamento	10
2.3.2.3. Processo C	10
2.3.2.3.1. Ideia	10
2.3.2.3.2. Tratamento	10
2.3.3. Tratamento de <i>outliers</i>	11
2.3.4. <i>Feature Selection</i>	11
2.4. Modelos desenvolvidos	12
2.4.1. Modelo 1: Regressão Linear	12
2.4.1.1. Resultado Obtido	12
2.4.2. Modelo 2: Árvore de Regressão Simples	12
2.4.2.1. Resultado Obtido	13
2.4.3. Modelo 3: <i>Gradient Boosted Trees</i>	13
2.4.3.1. Resultado Obtido	13
2.4.4. Modelo 4: Floresta de Decisão	13
2.4.4.1. Resultado Obtido	14
2.4.5. Modelo 5: Redes Neurais	14
2.4.5.1. Resultado Obtido	15
2.5. Resultados Obtidos e análise crítica	15
2.5.1. Resultado Obtido	15
2.5.2. Análise crítica	15
3. Dataset Atribuído	16

3.1. Domínios e Objetivos	16
3.2. Análise de Dados	16
3.2.1. Variável Alvo (Productions)	16
3.2.2. Variáveis de Produção Numérica e Risco de <i>Data Leakage</i>	17
3.2.3. Atributos Temporais (Date/Time)	18
3.2.4. Condições Meteorológicas (Temperatura, vento e Precipitação)	18
3.2.5. Variáveis de Radiação Solar	18
3.2.6. Conclusão sobre o Dataset	19
3.3. Tratamento de Dados	19
3.3.1. Limpeza Inicial dos Dados	19
3.3.2. Tratamento Comum dos Dados	20
3.3.3. Diferentes Processos de Tratamento	21
3.4. Modelos Desenvolvidos	22
3.4.1. Modelos de Classificação	23
3.4.2. Modelos de Clustering	23
3.5. Resultados Obtidos e Avaliação dos Modelos	24
3.6. Análise Crítica	26
3.6.1. Modelos de Classificação	26
3.6.2. Modelos de Clustering	26
4. Conclusões	28
Anexos	29

Lista de Figuras

Figura 1	Distribuição das distâncias percorridas por viagem (diagrama de caixa de bigode)	3
Figura 2	Estatísticas descritivas da coluna Trip_Distance_km (Statistics View)	3
Figura 3	Distribuição das ocorrências por período do dia (Time_of_Day)	3
Figura 4	Distribuição entre dias de semana e fim de semana (Day_of_Week)	4
Figura 5	Distribuição do número de passageiros por viagem (Passenger_Count)	5
Figura 6	Distribuição das condições de tráfego (Traffic_Conditions)	5
Figura 7	Distribuição das condições meteorológicas por viagem (Weather)	6
Figura 8	Distribuição da tarifa base (Base_Fare) — diagrama de caixa de bigode	6
Figura 9	Estatísticas descritivas da coluna Base_Fare (Statistics View)	6
Figura 10	Distribuição do custo por quilómetro (Per_Km_Rate) — diagrama de caixa de bigode	7
Figura 11	Estatísticas descritivas da coluna Per_Km_Rate (Statistics View)	7
Figura 12	Distribuição do custo por minuto (Per_Minute_Rate) — diagrama de caixa de bigode	7
Figura 13	Estatísticas descritivas da coluna Per_Minute_Rate (Statistics View)	7
Figura 14	Distribuição da duração das viagens em minutos (Trip_Duration_Minutes) — diagrama de caixa de bigode	7
Figura 15	Estatísticas descritivas da coluna Trip_Duration_Minutes (Statistics View)	7
Figura 16	Distribuição do custo total da viagem (Trip_Price) — diagrama de caixa de bigode	8
Figura 17	Estatísticas descritivas da coluna Trip_Price (Statistics View)	8
Figura 18	Matriz de correlação entre os atributos do dataset	8
Figura 19	Fluxo KNIME do Processo A de tratamento de missing values	9
Figura 20	Resultado do Processo A — métricas de avaliação do modelo	9
Figura 21	Fluxo KNIME do Processo B de tratamento de missing values	10
Figura 22	Resultado do Processo B — métricas de avaliação do modelo	10
Figura 23	Fluxo KNIME do Processo C de tratamento de missing values (remoção de linhas)	11
Figura 24	Resultado do Processo C — métricas de avaliação do modelo	11
Figura 25	Fluxo KNIME do processo de Feature Selection com regressão linear	11
Figura 26	Fluxo KNIME do Modelo 1 — Regressão Linear	12
Figura 27	Métricas de avaliação do Modelo 1 — Regressão Linear (Numeric Scorer)	12
Figura 28	Fluxo KNIME do Modelo 2 — Árvore de Regressão Simples	12
Figura 29	Métricas de avaliação do Modelo 2 — Árvore de Regressão Simples (Numeric Scorer)	13
Figura 30	Fluxo KNIME do Modelo 3 — Gradient Boosted Trees	13
Figura 31	Métricas de avaliação do Modelo 3 — Gradient Boosted Trees (Numeric Scorer)	13
Figura 32	Fluxo KNIME do Modelo 4 — Floresta de Decisão (Random Forest)	14
Figura 33	Métricas de avaliação do Modelo 4 — Floresta de Decisão (Numeric Scorer)	14
Figura 34	Fluxo KNIME do Modelo 5 — Redes Neurais	14
Figura 35	Métricas de avaliação do Modelo 5 — Redes Neurais (Numeric Scorer)	15
Figura 36	Distribuição da Variável Productions	17
Figura 37	Box Plot relacionando a energia em kWh com as classes categóricas originais.	17
Figura 38	Distribuição da Variável Wind_Direction_10m	18
Figura 39	Correlação Linear	19
Figura 40	Interior do metanó de pré-tratamento dos dados.	20
Figura 41	Processo de tratamento de dados A.	21
Figura 42	Ciclo automatizado de Feature Selection com KNN integrado.	21
Figura 43	Análise e resultados do processo de seleção de atributos (<i>Feature Selection</i>).	22
Figura 44	Processo de tratamento de dados B.	22

Figura 45	Processo de tratamento de dados C.	22
Figura 46	Modelos Criados	24

Lista de Tabelas

Tabela 1	Descrição detalhada dos atributos do dataset de viagens.	2
Tabela 2	Avaliação Global da (<i>Accuracy</i>) dos diferentes modelos de classificação testados.	25
Tabela 3	Matriz de Confusão: Distribuição dos Clusters K-Medoids face à Produção (Processo B). . . .	25
Tabela 4	Matriz de Confusão: Distribuição dos Clusters K-Means face à de Produção (Processo B). . .	25
Tabela 5	Matriz de Confusão: Distribuição dos Clusters K-Means face à de Produção (Processo C). . .	26
Tabela 6	Descrição detalhada dos atributos do dataset de energia.	29

1. Introdução

A Ciência de Dados e *Machine Learning* assumem um papel fundamental na resolução de problemas complexos em quase todos os setores da sociedade. A capacidade de extrair padrões de grandes volumes de dados permite criar modelos preditivos que vão auxiliar na automação e na tomada de decisão.

Este relatório documenta o trabalho prático desenvolvido utilizando a plataforma KNIME. O objetivo principal deste projeto é aplicar o ciclo completo de análise de dados e comparar diferentes algoritmos, abordando as duas principais tarefas de aprendizagem:

- **Problema de Classificação:** Uma tarefa onde o objetivo é classificar os dados em categorias específicas. Neste trabalho, esta abordagem é aplicada ao setor da energia, com o objetivo de prever o nível de produção energética.
- **Problema de Regressão:** Uma tarefa onde o objetivo é prever um valor numérico contínuo. Neste trabalho, esta abordagem é aplicada ao setor da mobilidade urbana, com o objetivo de prever o preço de uma viagem de táxi.

Ao longo do relatório, são detalhadas todas as etapas da construção destes modelos para cada um dos problemas. O relatório descreve a fase de Exploração e Tratamento de Dados, seguida da implementação e afinação de diversos algoritmos e por fim, apresenta-se a avaliação comparativa dos resultados, demonstrando o impacto que a qualidade dos dados e a escolha do modelo têm na resolução de problemas.

2. Dataset Grupo

O dataset escolhido pelo grupo foi um dataset do preço de uma viagem de taxi:

<https://www.kaggle.com/datasets/denkuznetz/taxi-price-prediction>

Trip_Distance_km, Time_of_Day, Day_of_Week, Passenger_Count, Traffic_Conditions, Weather, Base_Fare, Per_Km_Rate, Per_Minute_Rate, Trip_Duration_Minutes, Trip_Price

Campo (Coluna)	Descrição	Tipo	Missing Values
Trip_Distance_km	A distância percorrida durante a viagem, medida em quilômetros.	Contínuo	Sim
Time_of_Day	O período do dia em que a viagem começou.	Catégorico: "Afternoon", "Morning", "Evening", "Night"	Sim
Day_of_Week	Indica se a viagem ocorreu em um dia de semana ou fim de semana.	Catégorico: "Weekday", "Weekend"	Sim
Passenger_Count	O número de passageiros no táxi durante a viagem.	Contínuo	Sim
Traffic_Conditions	Intensidade do tráfego durante a viagem.	Catégorico: "Low", "Medium", "High"	Sim
Weather	Condição climática durante a viagem.	Catégorico: "Clear", "Rain", "Snow"	Sim
Base_Fare	A tarifa base inicial da corrida de táxi.	Contínuo	Sim
Per_Km_Rate	A taxa cobrada por quilômetro percorrido.	Contínuo	Sim
Per_Minute_Rate	A taxa cobrada por minuto de duração.	Contínuo	Sim
Trip_Duration_Minutes	O tempo total levado para a viagem em minutos.	Contínuo	Sim
Trip_Price	O custo total da viagem (Variável Alvo).	Contínuo	Sim

Tabela 1: Descrição detalhada dos atributos do dataset de viagens.

O atributo **Trip_Price** é o atributo objetivo deste problema e é o que será usado na previsão dos modelos.

2.1. Domínios e Objetivos

Este *dataset* possui como domínio a determinação do preço de uma viagem de táxi através dos seus parâmetros. Tendo em conta esse domínio foi determinado os seguintes objetivos:

1. Determinar o peso que cada parâmetro possui no custo de uma viagem.
2. Tratar os valores inconsistentes presentes no *dataset*.
3. Desenvolver um modelo que consiga prever de forma precisa preço de uma viagem de táxi através dos seus parâmetros.

2.2. Análise de dados

2.2.1. Trip_Distance

O dataset apresenta a seguinte distribuição relativamente às distâncias percorridas em cada viagem

Distância da viagem




Figura 1: Distribuição das distâncias percorridas por viagem (diagrama de caixa de bigode)

Como é possível ver através do diagrama de caixa de bigode que a maioria das viagens ocorre no intervalo de 12,628 km e 38,485 km

Name	Type	# Missing val...	# Unique valu...	Minimum	Maximum	25% Quantile	50% Quantile ...	75% Quantile	Mean
Trip_Distance_k	Number (Float)	50	867	1.23	146.067	12.628	25.83	38.485	27.071

Figura 2: Estatísticas descritivas da coluna Trip_Distance_km (Statistics View)

Através do nodo *statistics view* é possível ver a existência de 50 *missing values*, correspondentes a 5% de todas as entradas, que deverão ser tratados.

2.2.2. Time_of_Day

Distribuição do Tempo do dia




Figura 3: Distribuição das ocorrências por período do dia (Time_of_Day)

- Morning:

- definição: período entre o amanhecer e o meio-dia, ou especificamente entre a meia-noite e o meio-dia
 - ocorrências: 283
 - % ocorrências totais: 28,3%
- Afternoon:
 - definição: período do dia entre o meio-dia e o final da tarde.
 - ocorrências: 371
 - % ocorrências totais: 37,1%
- Evening:
 - definição: período final da tarde e início da noite
 - ocorrências: 203
 - % ocorrências totais: 20,3%
- Night:
 - definição: período entre o início da noite e o amanhecer
 - ocorrências: 93
 - % ocorrências totais: 9,3%
- ?:
 - definição: valor não apresentado
 - ocorrências: 50
 - % ocorrências totais: 5,0%

Como é possível ver o dataset apresenta a existências de 50 *missing values* que terão que ser tratados.

2.2.3. Day_of_Week

Distribuição entre dias de semana e fim de semana




Figura 4: Distribuição entre dias de semana e fim de semana (Day_of_Week)

- Weekend:
 - definição: Fim de semana
 - ocorrências: 295
 - % ocorrências totais: 29,5%
- Weekday:
 - definição: Dia da semana
 - ocorrências: 655
 - % ocorrências totais: 65,5%
- ?:
 - definição: valor não apresentado
 - ocorrências: 50
 - % ocorrências totais: 5,0%

Como é possível ver o dataset apresenta a existências de 50 *missing values* que terão que ser tratados.

2.2.4. Passengers_Counter

Passageiros




Figura 5: Distribuição do número de passageiros por viagem (Passenger_Count)

Como é possível ver o dataset apresenta uma distribuição equilibrada entre os diferentes tipos de passageiros. Para além disso o dataset apresenta a existências de 50 *missing values* que terão que ser tratados.

2.2.5. Condições de transito

O dataset apresenta a seguinte distribuição relativamente às condições de transito.

Distribuição de Traffic Conditions




Figura 6: Distribuição das condições de tráfego (Traffic_Conditions)

- Low:
 - definição: transito de intensidade baixa
 - ocorrências: 397
 - % ocorrências totais: 39,7%
- Medium:
 - definição: transito de intensidade média
 - ocorrências: 371
 - % ocorrências totais: 37,1%
- High:
 - definição: transito de intensidade elevada
 - ocorrências: 182
 - % ocorrências totais: 18,2%
- ?:
 - definição: valor não apresentado
 - ocorrências: 50
 - % ocorrências totais: 5,0%

Como é possível ver o dataset apresenta a sobre representação dos níveis médios e baixos de intensidade do transito. Também é possível ver a existências de 50 *missing values* que terão que ser tratados.

2.2.6. Weather

Meteorologia




Figura 7: Distribuição das condições meteorológicas por viagem (Weather)

- Clear:
 - definição: Tempo limpo
 - ocorrências: 667
 - % ocorrências totais: 66,7%
- Rain:
 - definição: Chuva
 - ocorrências: 227
 - % ocorrências totais: 22,7%
- Snow:
 - definição: Nevoadas
 - ocorrências: 56
 - % ocorrências totais: 5,6%
- ?:
 - definição: valor não apresentado
 - ocorrências: 50
 - % ocorrências totais: 5,0%

Como é possível ver o dataset apresenta a existências de 50 *missing values* que terão que ser tratados.

2.2.7. Base_Fare

O dataset apresenta a seguinte distribuição relativamente ao custo base de cada viagem

Distribuição do custo base



Figura 8: Distribuição da tarifa base (Base_Fare) — diagrama de caixa de bigode

Name	Type	# Missing val...	# Unique valu...	Minimum	Maximum	25% Quantile	50% Quantile ...	75% Quantile	Mean
Base_Fare	Number (Float)	50	290	2.01	5	2.73	3.52	4.262	3.503

Figura 9: Estatísticas descritivas da coluna Base_Fare (Statistics View)

Como é possível ver a maioria dos valores do custo base de uma viagem, apresentam-se no intervalo dos 2.73 unidade monetárias a 4.262 unidades monetárias.

2.2.8. Per_Km_Rate

Distribuição do custo por quilômetro




Figura 10: Distribuição do custo por quilômetro (Per_Km_Rate) — diagrama de caixa de bigode

Name	Type	# Missing val...	# Unique valu...	Minimum	Maximum	25% Quantile	50% Quantile ...	75% Quantile	Mean
Per_Km_Rate	Number (Float)	50	150	0.5	2	0.86	1.22	1.61	1.233

Figura 11: Estatísticas descritivas da coluna Per_Km_Rate (Statistics View)

Como é possível ver a maioria dos valores do custo por quilometro de uma viagem, apresentam-se no intervalo dos 0.86 unidade monetárias a 1.61 unidades monetárias.

2.2.9. Per_Minute_Rate

Distribuição do custo por minuto




Figura 12: Distribuição do custo por minuto (Per_Minute_Rate) — diagrama de caixa de bigode

Name	Type	# Missing val...	# Unique valu...	Minimum	Maximum	25% Quantile	50% Quantile ...	75% Quantile	Mean
Per_Minute_Rat	Number (Float)	50	41	0.1	0.5	0.19	0.29	0.39	0.293

Figura 13: Estatísticas descritivas da coluna Per_Minute_Rate (Statistics View)

Como é possível ver a maioria dos valores do custo por minuto de uma viagem, apresentam-se no intervalo dos 0.19 unidade monetárias a 0.39 unidades monetárias.

2.2.10. Trip_Duration_Minutes

Distribuição do tempo de uma viagem em minutos




Figura 14: Distribuição da duração das viagens em minutos (Trip_Duration_Minutes) — diagrama de caixa de bigode

Name	Type	# Missing val...	# Unique valu...	Minimum	Maximum	25% Quantile	50% Quantile ...	75% Quantile	Mean
Trip_Duration_Mi	Number (Float)	50	917	5.01	119.84	35.818	61.86	89.165	62.118

Figura 15: Estatísticas descritivas da coluna Trip_Duration_Minutes (Statistics View)

Como é possível ver a maioria dos valores do tempo de uma viagem, apresentam-se no intervalo dos 35.818 minutos a 89.165 minutos.

2.2.11. Trip_Price

Distribuição do custo de uma viagem



Figura 16: Distribuição do custo total da viagem (Trip_Price) — diagrama de caixa de bigode

Name	Type	# Missing val...	# Unique valu...	Minimum	Maximum	25% Quantile	50% Quantile ...	75% Quantile	Mean
Trip_Price	Number (Float)	49	951	6.127	332.044	33.736	50.075	69.194	56.875

Figura 17: Estatísticas descritivas da coluna Trip_Price (Statistics View)

Como é possível ver a maioria dos valores do custo de uma viagem, apresentam-se no intervalo dos 33.736 unidade monetárias a 69.194 unidades monetárias.

2.3. Tratamento de dados

O tratamento de dados foi um processo simples tendo abordados os seguintes passos:

1. **Correlação entre as diferentes tabelas**
2. **Tratamento dos *missing values***
3. **Tratamento de *outliers***
4. **Feature Selection**

2.3.1. Correlação entre as diferentes tabelas




Figura 18: Matriz de correlação entre os atributos do dataset

Como é possível ver os principais atributos que explicam as variações do preço de uma viagem são:

- *Trip_Distance_km*
- *Trip_Duration_Minutes*
- *Per_km_Rate*
- *Per_Minute_Rate*
- *Base_Fare*

2.3.2. Tratamento dos *missing values*

O tratamento dos *missing values* se sucedeu por uma análise da importância das colunas no atributo objetivo e da utilização do atributo R^2 , disponibilizado pelo *numeric scorer* para avaliar a performance do modelo.

2.3.2.1. Processo A

2.3.2.1.1. Ideia

A ideia do primeiro processo foi tentar reduzir ao máximo o número de entradas removidas para que o modelo tenha o máximo de informação possível.

2.3.2.1.2. Tratamento

No primeiro modelo, foi utilizado o seguinte tratamento de *missing values*:

Caso o valor da coluna *Trip_Price* não esteja especificada essa entrada será removida.

Caso o valor de colunas numéricas não esteja especificada essa entrada será alterada para o valor mediano dessa coluna.

Caso o valor de colunas textuais não esteja especificada essa entrada será alterada para o valor mais frequente.




Figura 19: Fluxo KNIME do Processo A de tratamento de missing values

RowID	Prediction (Trip_Price)
	.00 Number (Float)
R^2	0.832

Figura 20: Resultado do Processo A — métricas de avaliação do modelo

2.3.2.2. Processo B

2.3.2.2.1. Ideia

A ideia do segundo processo foi remover as entradas que não possuam valores categóricos definidos, tratar os valores numéricos pelo valor mediano.

2.3.2.2.2. Tratamento

No segundo modelo, foi utilizado o seguinte tratamento de *missing values*:

- Remoção de entradas de valores categóricos e o valor *target*, o custo da viagem.
- O valor mediano para valores numéricos




Figura 21: Fluxo KNIME do Processo B de tratamento de missing values

R ² :	0.875
Mean absolute error:	10.059
Mean squared error:	235.943
Root mean squared error:	15.36
Mean signed difference:	0.089
Mean absolute percentage error:	0.223
Adjusted R ² :	0.875

Figura 22: Resultado do Processo B — métricas de avaliação do modelo

2.3.2.3. Processo C

2.3.2.3.1. Ideia

A ideia do terceiro processo foi remover todas as linhas com *missing values*. Deixando apenas o modelo com valores completos permitindo assim ter um dataset mais preciso. É também de notar que este método reduzirá muito o número de dados disponibilizados para o modelo, pelo que poderá criar problemas de *overfitting*.

2.3.2.3.2. Tratamento

No terceiro modelo foi utilizado o *Row Filter* para remover todas as linhas com *missing values*




Figura 23: Fluxo KNIME do Processo C de tratamento de missing values (remoção de linhas)

RowID	Prediction (Trip_Price)
	.00 Number (Float)
R^2	0.88

Figura 24: Resultado do Processo C — métricas de avaliação do modelo

Como é possível ver o resultado do processo C é muito parecido ao resultado do processo B, pelo que na apresentação dos diferentes modelos serão usados os dois processos sendo demonstrado sempre o melhor tratamento com cada tipo de *learner*.

2.3.3. Tratamento de outliers

Na análise do *dataset* foi notado a existência de *outliers* nas colunas *Trip_Price* e *Trip_Distance*, no entanto na nossa análise, esses valores são realistas para o problema abordado, pois é normal que sejam efetuadas viagens até 146 km e que viagens mais longas tenham custos maiores para o cliente, como é visível quando comparamos os *outliers* presentes na coluna *Trip_Price* e na coluna *Trip_Distance*, pelo que não serão removido tendo em mente que a sua remoção aumentaria o *overfitting* do modelo tornando-o menos apropriado para análise do problema abordado.

Também é de notar que caso os *outliers* se localizassem em colunas como *Per_Km_Rate*, *Per_Minute_Rate* e *Base_Fare* o tratamento seria outro, pois significaria que certas viagens teriam tido custo muito maiores que poderiam ter sido explicados por fatores externos aos abordados neste problema.

2.3.4. Feature Selection

O processo de feature selection decorreu através da utilização dos *nodes*, **Feature Selection Loop Start** e **Feature Selection Loop End**, através de um modelo de regressão linear.




Figura 25: Fluxo KNIME do processo de Feature Selection com regressão linear

Através do **Feature Selection Filter**, foi possível verificar que a remoção de *features* seria desnecessária.

2.4. Modelos desenvolvidos

2.4.1. Modelo 1: Regressão Linear

- Tratamento de *missing values*: **Processo C**
- *Learner*: Linear Regression
- *Predictor*: Regression




Figura 26: Fluxo KNIME do Modelo 1 — Regressão Linear

2.4.1.1. Resultado Obtido

R ² :	0.88
Mean absolute error:	8.767
Mean squared error:	197.857
Root mean squared error:	14.066
Mean signed difference:	1.514
Mean absolute percentage error:	0.227
Adjusted R ² :	0.88

Figura 27: Métricas de avaliação do Modelo 1 — Regressão Linear (Numeric Scorer)

2.4.2. Modelo 2: Árvore de Regressão Simples

- Tratamento de *missing values*: **Processo B**
- *Learner*: Simple Regression Tree
- *Predictor*: Simple Regression Tree




Figura 28: Fluxo KNIME do Modelo 2 — Árvore de Regressão Simples

2.4.2.1. Resultado Obtido

R^2 :	0.842
Mean absolute error:	12.46
Mean squared error:	297.097
Root mean squared error:	17.237
Mean signed difference:	-1.224
Mean absolute percentage error:	0.246
Adjusted R^2 :	0.842

Figura 29: Métricas de avaliação do Modelo 2 — Árvore de Regressão Simples (Numeric Scorer)

2.4.3. Modelo 3: *Gradient Boosted Trees*

- Tratamento de *missing values*: **Processo B**
- *Learner*: Simple Regression Tree
 - N° de Modelos: 250
 - *Learning Rate*: 0.1
 - α : 0.95
- *Predictor*: Simple Regression Tree




Figura 30: Fluxo KNIME do Modelo 3 — Gradient Boosted Trees

2.4.3.1. Resultado Obtido

R^2 :	0.943
Mean absolute error:	5.853
Mean squared error:	107.642
Root mean squared error:	10.375
Mean signed difference:	-1.102
Mean absolute percentage error:	0.102
Adjusted R^2 :	0.943

Figura 31: Métricas de avaliação do Modelo 3 — Gradient Boosted Trees (Numeric Scorer)

2.4.4. Modelo 4: Floresta de Decisão

- Tratamento de *missing values*: **Processo B**
- *Learner*: Simple Regression Tree
 - N° Modelos: 250
- *Predictor*: Simple Regression Tree




Figura 32: Fluxo KNIME do Modelo 4 — Floresta de Decisão (Random Forest)

2.4.4.1. Resultado Obtido

R^2 :	0.932
Mean absolute error:	7.658
Mean squared error:	128.251
Root mean squared error:	11.325
Mean signed difference:	-0.911
Mean absolute percentage error:	0.153
Adjusted R^2 :	0.932

Figura 33: Métricas de avaliação do Modelo 4 — Floresta de Decisão (Numeric Scorer)

2.4.5. Modelo 5: Redes Neurais

- Tratamento de *missing values*: **Processo B**
- *Learner*: Simple Regression Tree
 - Nº de iterações: 200
 - *hidden layers*: 1
 - *neurons por layer*: 16
- *Predictor*: Simple Regression Tree




Figura 34: Fluxo KNIME do Modelo 5 — Redes Neurais

2.4.5.1. Resultado Obtido

R^2 :	0.95
Mean absolute error:	0.018
Mean squared error:	0.001
Root mean squared error:	0.03
Mean signed difference:	-0.002
Mean absolute percentage error:	0.155
Adjusted R^2 :	0.95

Figura 35: Métricas de avaliação do Modelo 5 — Redes Neurais (Numeric Scorer)

2.5. Resultados Obtidos e análise crítica

2.5.1. Resultado Obtido

Através da análise dos diversos modelos apresentados foi possível verificar que o melhor modelo será o modelo 5 que utiliza o processo *B* e que usa *Redes Neurais*, pois apresenta um valor de R^2 maior que todos os outros modelos, apresentando assim uma melhor aproximação dos valores previstos e valores objetivos.

Também é de notar que apesar do modelo de redes neurais possuir um valor R^2 maior, quando comparado com outros modelos como o modelo que usa *Gradient Boosted Trees* é possível afirmar que a diferença entre os dois modelos é baixa o suficiente para que alterações na *seed* poderão alterar o modelo que obtém uma melhor performance sendo possível.

2.5.2. Análise crítica

De acordo com o estudo que fizemos sobre este *dataset* fomos capazes de concluir que, apesar dos atributos nele presentes necessitarem de pouco tratamento, foi possível avaliar a importância de cada coluna para o valor de final de uma viagem onde atributos como *Trip_Distance_km*, *Trip_Duration_Minutes*, *Per_km_Rate*, *Per_Minute_Rate*, *Base_Fare* afetam de forma elevada o valor final de uma viagem.

3. Dataset Atribuído

O Dataset utilizado neste projeto junta informação de duas áreas de energia e meteorologia. Cada linha da tabela mostra como estava o clima num determinado momento, incluindo dados como temperatura, radiação solar, humidade, chuva e o estado do vento. Ao lado dessa informação meteorológica, o dataset indica também quanta energia foi produzida e nesse mesmo período por diferentes tecnologias. A descrição detalhada de todos estes atributos, os seus tipos e a presença de valores nulos, podem ser consultada na tabela_energia

3.1. Domínios e Objetivos

O nosso principal foco neste estudo é o atributo “Productions”, que funciona como o nosso target, o atributo alvo que queremos prever. Esta coluna divide o total da produção de energia em categorias. Como estamos a tentar adivinhar uma categoria e não um número exato, estamos perante um problema de Classificação.

A ideia para este trabalho surge da necessidade de ajudar a gerir melhor as redes elétricas. Com o aumento do uso de energias renováveis, a produção de energia depende muito do clima e torna-se mais imprevisível. Por isso, o nosso objetivo é desenvolver modelos de *Machine Learning* que consigam prever qual vai ser o nível de produção de energia.

Na prática, um sistema que consiga fazer estas previsões tem muito valor. Ele vai ajudar os gestores da rede elétrica a saberem com alguma antecedência se vai sobrar ou faltar energia. Dessa forma, conseguem organizar-se melhor ao gerir o armazenamento de energia, evitar falhas no fornecimento de luz e garantir que se aproveita ao máximo as fontes de energia limpa.

3.2. Análise de Dados

Antes de iniciar qualquer processo de tratamento e modelação, é preciso compreender os dados fornecidos. Esta secção apresenta a exploração inicial realizada sobre o *dataset*. O objetivo é identificar problemas e garantir que os dados estão preparados para as seguintes fases.

3.2.1. Variável Alvo (Productions)

O *dataset* apresenta a seguinte distribuição relativamente ao atributo alvo, que categoriza a produção de energia:




Figura 36: Distribuição da Variável Productions

Durante a exploração inicial, detetou-se um problema de consistência semântica na formatação desta variável categórica. Foram identificados registos com nomes distintos que remetem para o mesmo significado prático. Por exemplo, a classe alta produção aparece escrita como “High Production” e “Alto”, enquanto a classe baixa produção surge com variações como “Low” e “lw” e entre outras.

Esta inconsistência cria classes artificiais que obrigou uma normalização e agrupamento textual antes de qualquer modelação.

3.2.2. Variáveis de Produção Numérica e Risco de *Data Leakage*

O *dataset* contém várias colunas contínuas que representam os valores exatos de energia gerada em kWh (Cogeneration, Wind, Photovoltaics, Hydro, Other Technologies e Distribution Network).




Figura 37: Box Plot relacionando a energia em kWh com as classes categóricas originais.

Sendo o objetivo deste trabalho prever a categoria de produção de energia, a presença destas variáveis numéricas introduz um risco de *Data Leakage*. A análise visual do diagrama *Box Plot* acima revelou dois problemas.

Primeiro, detetou-se uma anomalia na catalogação dos dados originais: a ordem lógica dos valores de energia está corrompida (por exemplo, as classes “Medium Production” e “Medio” apresentam valores de kWh significativamente mais elevados que as classes de alta produção como “High”, “Alto” e “Hgh”).

Segundo, apesar desta falta de coerência, as diferentes categorias ocupam intervalos de kWh distintos. Se estas colunas fossem fornecidas aos algoritmos, os modelos iam limitar-se a mapear os valores de kWh para a categoria correspondente, ignorando as variáveis climáticas e invalidando o propósito do projeto.

Foi assim preciso a remoção destas colunas. De igual forma, a variável RowID foi identificado como um identificador da tabela sem qualquer valor analítico.

3.2.3. Atributos Temporais (Date/Time)

A análise da coluna de data e hora revelou ser importante, porque apesar da maioria dos registos sigam uma cadência normal, exploração inicial detetou anomalias temporais tais como:

- Foram encontradas dias impossíveis no calendário (ex: dia 32).
- Foram detetados meses inexistentes (ex: mês 13).
- Foi identificado registos com o ano 2027, o que representa dados “do futuro” em relação ao limite temporal do projeto.

Estas inconsistências exigiram um tratamento através de expressões regulares para evitar a introdução de ruído no modelo, além disso, verificou-se a existência de *missing values* nesta coluna.

3.2.4. Condições Meteorológicas (Temperatura, vento e Precipitação)

A análise das estatísticas descritivas das variáveis climáticas mostrou as seguintes distribuições:




Figura 38: Distribuição da Variável Wind_Direction_10m

Como o gráfico ilustra, as várias direções do vento distribuídas, verificou-se que contêm *missing values* visto pela fatia vermelha. Variáveis como esta (Wind_Direction_10m e Wind_Direction_100m) encontram-se em formato de texto e necessitarão de conversão matemática (*One-Hot Encoding*) para poderem ser processados pelos algoritmos.

3.2.5. Variáveis de Radiação Solar

O *dataset* possui múltiplas colunas dedicadas à medição de radiação (direct_radiation, diffuse_radiation, shortwave_radiation, etc.).

A matriz de correlação entre variáveis numéricas revelou valores de correlação elevados entre estas diferentes métricas de radiação solar.




Figura 39: Correlação Linear

3.2.6. Conclusão sobre o Dataset

A exploração inicial permitiu identificar não apenas problemas de qualidade de dados, como os *missing values*, mas também inconsistências lógicas que poderiam comprometer a modelação.

- **Inconsistência da Variável Alvo:** A presença de variações textuais para a mesma categoria obriga uma normalização das classes para que o modelo de classificação perceba o seu objetivo corretamente.
- **Inconsistências Temporais:** A presença de datas inválidas indica falhas na recolha ou registo de dados, obrigando à eliminação dessas linhas para manter a integridade cronológica.
- **Qualidade e Redundância de Atributos:** A presença de valores nulos ditará a necessidade de técnicas específicas para cada coluna. Por outro lado, a alta correlação entre variáveis levanta a hipótese de sobreajuste (*overfitting*), motivando a criação de diferentes *pipelines* de tratamento de dados para avaliar o peso real destas colunas.
- **Risco de Data Leakage:** A identificação das colunas numéricas de produção (kWh) e do RowId obriga à sua remoção antes da modelação, garantindo que os algoritmos aprendem exclusivamente através do clima.

3.3. Tratamento de Dados

A qualidade dos dados é um dos fatores mais importantes na concessão de qualquer sistema de aprendizagem. Assim, uma preparação rigorosa foi levada a cabo antes da aplicação dos modelos.

3.3.1. Limpeza Inicial dos Dados

A primeira etapa consistiu na limpeza dos dados, onde foram resolvidos problemas de consistência e validade dos valores presentes:




Figura 40: Interior do metanó de pré-tratamento dos dados.

- **Filtro de Data Leakage:** Recorrendo ao nó *Column Filter*, procedeu-se à eliminação de atributos para evitar o risco de fuga de informação. Todas as colunas numéricas de energia em kWh e a variável identificadora RowID foram descartadas. Isto foi feito porque as colunas de energia representam o resultado direto da produção, o que permitiria aos modelos “fazer batota”.
- **Remoção de Variáveis com Ruído:** As variáveis rain e precipitation foram removidas por apresentarem um volume elevado de *missing values* cerca de 80%. A coluna snowfall também foi eliminada devido à sua variância quase nula, não oferecendo qualquer informação relevante aos modelos.
- **Limpeza Semântica e Conversão de Tipos:** Detetou-se que a coluna diffuse_radiation estava formada incorretamente como texto devido à presença da palavra “nan” nas células. Recorreu-se ao nó *String Manipulation (Multi Column)* para limpar esta anomalia, permitindo a conversão para o formato correto através do nó *String to Number*.
- **Validação Temporal:** Algumas datas apresentavam-se inválidas. Configurou-se dois nós *Row Filter* sequencias num utilizou-se *matches regex* para descartar os registos corrompidos e no outro utilizou-se *matches wildcards* para retirar valores com datas futuras à atual, assim assegurando a coerência cronológica do dataset.
- **Normalização do Atributo Alvo:** O nó *Rule Engine* foi utilizado para

3.3.2. Tratamento Comum dos Dados

A criação de variáveis derivadas e a transformação das existentes visou otimizar a compatibilidade com os algoritmos de aprendizagem utilizados:

- **Atributos Temporais:** A coluna de data original foi convertida para um objeto temporal. Em seguida utilizou-se o nó *Date&Time Part Extractor* para criar variáveis independentes contendo o Mês, o Dia da Semana e a Hora. Esta extração vai servir para que os modelos captem padrões de sazonalidade climática.
- **Codificação Categórica (One-Hot Encoding):** As variáveis qualitativas referentes à direção do vento foram alvo de *One-Hot Encoding* através do nó *One to Many*, que as representa de forma binária. Esta técnica é importante para modelos como o de Regressão Logística e Redes Neurais, uma vez que estes algoritmos são matemáticos e não conseguem interpretar texto.
- **Tratamento de Outliers:** Aplicou-se o nó *Numeric Outliers* para detetar e nivelar valores extremos nas variáveis contínuas. Embora em contexto meteorológico os extremos possam representar fenómenos reais, testes empíricos de validação demonstraram comportamentos distintos consoante a natureza do algoritmo, enquanto em modelos baseados em árvores sofreram oscilações residuais (inferiores a 1%), algoritmos como as Redes Neurais, registaram ganhos próximos de 2%. Optou-se assim pela manutenção da filtragem de outliers.
- **Partição dos Dados:** O dataset foi dividido através do nó *Partitioning* (80% para treino e 20% para teste)

- **Normalização:** Os dados numéricos foram escalonados (0 a 1) com o nó *Normalizar*. O cálculo foi feito nos dados de treino, sendo depois replicado para os dados de teste através do nó *Normalizer (Apply)*.

3.3.3. Diferentes Processos de Tratamento

Para lidar com a elevada correlação e com os *missing values*, o fluxo foi criado três processos diferentes para avaliação e comparação.

1. Processo A:

Nesta abordagem, optou-se por não fazer o tratamento dos *missing values*. Com o objetivo de explorar a capacidade dos algoritmos ao lidar com valores em falta, avaliando a sua performance com o *dataset* com lacunas.




Figura 41: Processo de tratamento de dados A.

2. Processo B:

Com o objetivo de reduzir o *overfitting*, esta abordagem foca-se na otimização dos atributos. Os valores nulos foram primeiro tratados através do nó *Missing Value* com estratégias específicas para cada tipo de dado:

- **interpolação linear:** Utilizou-se para as variáveis numéricas contínuas,
- **Valor mais Frequente:** Para as variáveis categóricas
- **Previous Value:** para os atributos temporais.

Após fornecer uma matriz completa, implementou-se um ciclo de seleção de atributos (*Backward Feature Elimination*) suportado por um algoritmo *K-Nearest Neighbors* (KNN).




Figura 42: Ciclo automatizado de Feature Selection com KNN integrado..

#	RowID	Nr. of features (= Number (Integer))	Accuracy (= Number (Float))	Removed feature (= String)
1	All	13	0.483	
2	12	12	0.517	Hour
3	11	11	0.528	direct_radiation (W/m²)
4	10	10	0.541	wind_speed_10m (km/h)
5	9	9	0.556	shortwave_radiation (W/m²)
6	8	8	0.557	direct_normal_irradiance (W/m²)
7	7	7	0.561	diffuse_radiation (W/m²)
8	6	6	0.561	terrestrial_radiation (W/m²)
9	5	5	0.574	cloud_cover (%)
10	4	4	0.58	relative_humidity_2m (%)
11	3	3	0.508	temperature_2m (°C)
12	2	2	0.438	Day of Week (Number)
13	1	1	0.407	Month (Number)

Figura 43: Análise e resultados do processo de seleção de atributos (*Feature Selection*).

O ciclo eliminou as colunas com menor contributo preditivo, isolando exclusivamente as métricas vitais para a classificação. No final deste ciclo de otimização, o modelo determinou a exclusão das seguintes variáveis: Date/Time, cloud_cover, wind_speed_10m, direct_radiation, shortwave_radiation, diffuse_radiation, direct_normal_irradiance e terrestrial_radiation.




Figura 44: Processo de tratamento de dados B.

3. Processo C:

Nesta abordagem, optou-se por reter a totalidade das variáveis. Esta ramificação sofreu exatamente o mesmo tratamento de *missing values* que no processo B, fornecendo assim a tabela de dados completa e com todas as colunas originais a todos os algoritmos.




Figura 45: Processo de tratamento de dados C.

3.4. Modelos Desenvolvidos

À medida que fomos avançando no projeto, fomos desenvolvendo vários modelos de Machine-Learning, nomeadamente modelos de Decision Tree, Logistic Regression, Random Forest, Multi-Layer Perceptron, K-Means, K-Medoids, Gradient Boosted Trees e o modelo desenvolvido pela Keras.

Nesta secção, explicamos as técnicas de *Machine Learning* que usámos para prever a produção de energia. Esta parte do trabalho foi dividida em duas partes: modelos de classificação e modelos de *Clustering*.

Para termos a certeza dos resultados, corremos estes algoritmos em três versões diferentes dos nossos dados (Processo A, B e C). Isto permitiu-nos perceber se as técnicas de tratamento e limpeza de dados realmente melhoravam o desempenho dos modelos.

3.4.1. Modelos de Classificação

Para a parte de classificação, tentámos escolher modelos variados, desde árvores de decisão simples até redes neuronais, para podermos comparar qual se adaptava melhor ao nosso problema. Os modelos desenvolvidos foram:

- **Decision Tree:** Usado como o nosso modelo de base. É um algoritmo simples e fácil de interpretar, porque nos permite ver as regras que ele cria com base no clima (por exemplo, regras com o vento ou a radiação).
- **Logistic Regression:** Um modelo estatístico mais clássico. Serviu para ver se as diferentes classes de energia podiam ser separadas de forma linear e para servir de termo de comparação.
- **Random Forest:** É um modelo que junta dezenas de árvores de decisão diferentes. Escolhemos este modelo porque ele lida muito bem com ruído e valores extremos (*outliers*), algo que acontece com muita frequência em dados meteorológicos.
- **Gradient Boosted Trees:** Também usa várias árvores, mas de forma sequencial. É uma boa opção quando queremos tentar uma melhor *Accuracy* possível dos dados.
- **Multi-Layer Perceptron (MLP):** Uma rede neuronal básica. Foi testada para tentar encontrar relações mais complexas e escondidas entre o clima e a energia, que os modelos mais simples não conseguem ver.
- **Deep Learning (Keras):** Uma arquitetura de rede neuronal mais avançada. Embora demore muito mais tempo a treinar, utilizámos esta ferramenta para tentar extrair o máximo de padrões possíveis do *dataset*.

No final, pegámos nos modelos que tiveram melhores resultados (como o *Random Forest* e o *Gradient Boosted Trees*) e fizemos algumas alterações nos seus hiperparâmetros para tentar subir ainda mais a taxa de *Accuracy*.

3.4.2. Modelos de Clustering

Para além de classificação, usámos técnicas de *Clustering* para ver se os dados do clima, se organizavam em grupos parecidos com as classes de energia. Para isto usámos a tabela inteira, sem dividir os dados de treino e teste, e aplicámos os seguintes modelos:

- **K-Means:** É um algoritmo clássico que agrupa os dados usando as distâncias matemáticas entre eles. Foi útil para identificar rapidamente os principais perfis de clima do nosso *dataset*.
- **K-Medoids:** É uma versão muito parecida ao K-Means, mas mais resistente a anomalias do clima. Em vez de usar um ponto matemático imaginário como centro do grupo, ele escolhe uma linha real do nosso *dataset*. Usámos este modelo para comparar com o K-Means e confirmar se os grupos criados eram realmente consistentes.




Figura 46: Modelos Criados

3.5. Resultados Obtidos e Avaliação dos Modelos

A avaliação dos modelos que desenvolvemos foi feita usando métricas adequadas para cada tipo de problema:

- **Classificação:** Como a nossa variável-alvo (*Productions*) era categórica, usámos principalmente a *Accuracy* para avaliar os modelos. Para garantir a fiabilidade, dividimos os dados em 80% para treino e 20% para teste.

- **Clustering:** Sendo modelos não supervisionados, usamos uma abordagem de avaliação indireta, Cruzamos os grupos criados pelos algoritmos com as categorias de produção através de matrizes de confusão.

A aplicação dos diferentes algoritmos aos três processos de tratamento de dados (A, B e C) gerou os resultados nas tabelas seguintes.

Algoritmo / Modelo	Processo A	Processo B	Processo C	Versão Otimizada (Teste 1)	Versão Otimizada (Teste 2)
Decision Tree	52,99%	43,70%	39,83%	50,77%	-
Logistic Regression	-	44,05%	44,16%	44,05%	-
Random Forest	54,30%	53,22%	52,08%	60,06%	59,54%
Multi-Layer Perceptron (MLP)	-	48,95%	48,03%	46,90%	-
Deep Learning (Keras)	-	50,14%	49,12%	-	-
Gradient Boosted Trees	55,16%	54,02%	54,53%	57,72%	-

Tabela 2: Avaliação Global da (*Accuracy*) dos diferentes modelos de classificação testados.

Cluster (Medoid)	High	Low	Medium	Medium-High	Medium-Low	Total
Row3410	696	413	86	185	825	2 205
Row5316	412	266	74	176	402	1 330
Row595	230	334	434	439	110	1 547
Row6496	660	465	182	373	679	2 359
Row7877	417	298	44	138	437	1 334
Total	2 415	1 776	820	1 311	2 453	8 775

Tabela 3: Matriz de Confusão: Distribuição dos Clusters K-Medoids face às Produção (Processo B).

Cluster	High	Low	Medium	Medium-High	Medium-Low	Total
Cluster 0	679	478	174	380	689	2 400
Cluster 1	139	257	419	365	73	1 253
Cluster 2	446	318	55	172	451	1 442
Cluster 3	413	273	81	181	400	1 348
Cluster 4	738	450	91	213	840	2 332
Total	2 415	1 776	820	1 311	2 453	8 775

Tabela 4: Matriz de Confusão: Distribuição dos Clusters K-Means face às de Produção (Processo B).

Cluster	High	Low	Medium	Medium-High	Medium-Low	Total
Cluster 0	366	139	39	56	355	955
Cluster 1	240	199	72	118	269	898
Cluster 2	285	199	185	179	289	1 137
Cluster 3	294	180	58	119	351	1 002
Cluster 4	1 230	1 059	466	839	1 189	4 783
Total	2 415	1 776	820	1 311	2 453	8 775

Tabela 5: Matriz de Confusão: Distribuição dos Clusters K-Means face às de Produção (Processo C).

Os resultados expostos nestas tabelas evidenciam diferenças entre os processos e os algoritmos, cujo significado e impacto serão detalhadamente interpretados no subcapítulo seguinte.

3.6. Análise Crítica

Com base na avaliação feita no subcapítulo anterior, passamos agora a analisar os resultados obtidos por cada tipo de modelo. Esta análise ajuda-nos a perceber porque é que uns algoritmos são melhor do que outros no nosso caso de estudo.

3.6.1. Modelos de Classificação

Através deste resultados foi possível verificar as seguintes observações:

- O processo de otimização de hiperparâmetros nos nós do tipo *Learner* proporcionou uma melhoria significativa no desempenho geral, aumentando a *accuracy* dos modelos baseados em árvores de decisão significativamente.
- O processo de tratamento de dados A teve um melhor desempenho nos algoritmos de aprendizagem baseados em árvores de decisão, tendo o processo B desempenhado melhor no modelo de *Deep Learning*, e o modelo C tendo desempenhado melhor no modelo de *Logistic Regression*.
- O modelo *Logistic Regression* apresenta uma diferença de desempenho muito próxima entre processos pelo que divergências na *seed* usada poderá causar a que o processo que se desempenhe melhor seja alterado.

Os resultados variaram bastante dependendo da técnica usada. Os modelos mais matemáticos, como a Regressão Logística e a *Decision Tree* simples, tiveram os piores resultados, provando que não conseguem lidar bem com a complexidade do clima. Por outro lado, o nosso melhor algoritmo foi o *Random Forest* que obteve a melhor *Accuracy* de todos com 60,06% na versão otimizada. O sucesso deste modelo explica-se por ser um método baseado em árvores, o que torna muito mais resistente ao ruído e aos *outliers* frequentes nos dados meteorológicos, captando melhor as interações complexas do clima.

3.6.2. Modelos de Clustering

Na avaliação do algoritmo K-Medoids foi possível observar, o seguinte:

- O algoritmo K-Medoids não conseguiu isolar claramente nenhuma classe de produção num cluster específico. Todos os clusters contêm uma mistura acentuada de todas as classes.
- O Row3410 (Cluster 1) e o Row6496 (Cluster 4) são os maiores grupos e concentram a maioria dos dados, mas ambos têm picos semelhantes nas classes extremas (High e Medium-Low). O Row595 é o único que

mostra uma ligeira tendência para capturar valores intermédios (Medium e Medium-High), com 434 e 439 instâncias respetivamente.

Na avaliação do algoritmo K-Means, processo B, foi possível observar, o seguinte:

- O K-Means no Processo B reflete quase a mesma distribuição do K-Medoids.
- O Cluster 1 conseguiu uma diferenciação interessante: tem uma presença muito baixa de classes extremas (High com 139 e Medium-Low com 73) e focou-se visivelmente nas classes centrais (Medium com 419 e Medium-High com 365). Isto indica que este cluster identifica um perfil de produção estável.

Na avaliação do algoritmo K-Means, processo C, foi possível observar, o seguinte:

- Existe uma forte assimetria no Processo C. O Cluster 4 absorveu a grande maioria dos dados (4 783 instâncias de um total de 8 775). Devido a isso, o algoritmo perde poder de discriminação, falhando em separar os perfis de produção de forma útil.
- Os restantes clusters (0, 1, 2 e 3) dividem o resto dos dados em partes quase iguais, mas mantêm uma distribuição interna muito homogénea e sem um perfil claro.

Nos modelos não supervisionados, os resultados provaram que as escolhas que fizemos no tratamento de dados foram essenciais. No processo C, o algoritmo *K-means* teve um desempenho muito fraco, em que no *Cluster 4* absorveu mais de metade de todo o *dataset* sem separar nada de útil. No entanto, no processo B, o grande destaque foi a descoberto de um padrão tanto no *K-means* como *K-Medoids* conseguiram isolar um grupo focado quase exclusivamente nos dias de produção intermédia (*Medium* e *Medium-High*). Como estes dois algoritmos usam matemáticas diferentes para encontrar os centros dos grupos, o facto de ambos terem chegado exatamente ao mesmo resultado de forma “cega” prova que o tratamento de dados feito no processo B foi a mais correta e eficaz.

4. Conclusões

Considera-se que a componente do trabalho focada no problema de regressão, foi concluída com sucesso. O grupo conseguiu explorar diversos modelos de regressão, aplicar conhecimentos dados nas aulas sobre tratamento de dados e a aplicação de uma forma iterativa a alteração de parâmetros dos modelos e as suas consequências no resultado final.

A maior dificuldade encontrada na análise do dataset do grupo foi a fase de exploração do uso diferentes processos de tratamento de dados, especialmente o no tratamento de *missing values* e os seus efeitos nos resultados obtidos nos modelos.

Considera-se que a componente do trabalho focada no problema de classificação, foi concluída com sucesso. O grupo conseguiu aplicar de forma iterativa os conhecimentos adquiridos na unidade curricular, construindo uma *pipeline* analítica completa na plataforma KNIME.

A maior dificuldade enfrentada nesta parte do projeto foi na fase de exploração e preparação dos dados. O *dataset* atribuído, revelou um elevado grau de ruído e diversas anomalias estruturais. Assim, foi exigido um esforço para poder identificar e contornar estes problemas, destacando-se o risco de *Data Leakage*, a inconsistência semântica das classes da variável alvo e a presença de datas impossíveis no calendário cronológico. Na fase de modelação, foi possível implementar e comparar uma grande diversidade de algoritmos, desde modelos algébricos como Regressão Logística e Redes Neurais, até modelos baseados em árvores. Conclui-se que o modelo *Random Forest*, revelou ser o mais adequado para este tipo de dados, tendo alcançado a melhor *Accuracy* global de 60%.

Anexos

Campo (Coluna)	Descrição	Tipo	Missing Values
RowID	Identificação única de cada linha no dataset.	Identificador	Não
Date/Time	Data e hora exata do registo meteorológico e de energia.	Data / Tempo	Sim
Cogeneration (kWh)	Produção de energia em unidades de Cogeração (KiloWatt-hora).	Contínuo	Sim
Wind (kWh)	Produção de energia em unidades Eólicas (KiloWatt-hora).	Contínuo	Sim
Photovoltaics (kWh)	Produção de energia em unidades Fotovoltaicas (KiloWatt-hora).	Contínuo	Sim
Hydro (kWh)	Produção de energia em unidades Hídricas (KiloWatt-hora).	Contínuo	Sim
Other Technologies (kWh)	Produção de energia noutras tecnologias (KiloWatt-hora).	Contínuo	Sim
Distribution Network (kWh)	Produção total de energia na Rede de Distribuição (KiloWatt-hora).	Contínuo	Sim
temperature_2m (°C)	Temperatura exterior medida a 2 metros de altura (°C).	Contínuo	Sim
relative_humidity_2m (%)	Humidade relativa exterior medida a 2 metros de altura (%).	Contínuo	Sim
precipitation (mm)	Precipitação exterior total (Milímetros).	Contínuo	Sim

rain (mm)	Quantidade de chuva exterior (Milímetros).	Contínuo	Sim
snowfall (cm)	Quantidade de queda de neve exterior (Centímetros).	Contínuo	Sim
cloud_cover (%)	Percentagem de cobertura de nuvens no céu (%).	Contínuo	Sim
Wind_Direction_10m	Direção qualitativa do vento a 10 metros de altura.	Categórico	Sim
wind_speed_10m (km/h)	Velocidade do vento a 10 metros de altura (Quilómetros/Hora).	Contínuo	Sim
Wind_Direction_100m	Direção qualitativa do vento a 100 metros de altura.	Categórico	Sim
wind_speed_100m (km/h)	Velocidade do vento a 100 metros de altura (Quilómetros/Hora).	Contínuo	Sim
direct_radiation (W/m ²)	Radiação emitida diretamente pelo sol (Watts/Metro Quadrado).	Contínuo	Sim
shortwave_radiation (W/m ²)	Radiação de onda curta emitida pelo sol (Watts/Metro Quadrado).	Contínuo	Sim
diffuse_radiation (W/m ²)	Radiação difusa emitida pelo sol (Watts/Metro Quadrado).	Contínuo	Sim
direct_normal_irradiance (W/m ²)	Feixe de radiação normal direta emitido pelo sol (Watts/Metro Quadrado).	Contínuo	Sim
terrestrial_radiation (W/m ²)	Radiação de onda longa emitida pela superfície terrestre (Watts/Metro Quadrado).	Contínuo	Sim
Productions	Taxa de produção dividida em classes (Variável Alvo).	Categórico	Sim

Tabela 6: Descrição detalhada dos atributos do dataset de energia.